RSI、反馈与学习动力学

价值、认识与学习机制的自我修改｜文献综述

打开文献阅读地图与独立解读

递归自我改进（RSI）关心的是：系统学到的能力，能否帮助它改进下一轮学习？例如，会写代码的系统可以修改自己的工具，也可以修改负责生成改进方案的程序。两者都属于自修改，但改变的环节不同。本文按价值、认识和学习机制梳理这些研究，再讨论同一反馈循环为何既可能推动进步，也可能维持错误。

类别	修改什么	需要回答的问题
价值与评价	目标、训练奖励、评分规则	凭什么判断修改更好?
认识与交互	工具、实验选择、世界模型	怎样获得并理解纠错证据?
学习机制	更新规则、架构、记忆、改进程序	怎样让下一轮更会学习?

一、价值与评价：先区分训练奖励与最终目标

奖励是训练时给学习者的信号，最终目标是评价学习结果的标准。Singh 等说明，两者可以不同：只奖励眼前收益，可能学不到以后有用的探索行为；合适的内部奖励反而能提高长期收益。价值函数则是在给定奖励下估计预期回报。改进估计、改写奖励、改变目标，是三个不同问题。

固定最终目标时，奖励设计可写成下面的双层优化。先按奖励 r 训练出策略 A(r)，再用外部标准 J 评价它；选择的是训练效果最好的奖励：

$$r^{*} \in \operatorname{argmax}_{r} E[J(A(r))]$$

期望表示对训练随机性取平均。Eureka 把这一思路做成循环：语言模型写奖励代码，强化学习算法据此训练策略，再把训练结果交回语言模型修改奖励。作者比较一次生成更多候选与分轮使用反馈，也检查去掉各奖励项的训练统计会怎样。结果支持反馈能帮助奖励搜索。在固定任务目标下，它改进的是训练手段。

目标本身改变时，需要说明按谁的标准评价

Everitt 等研究效用函数也可被修改的主体。若用修改后的标准评价修改，主体可能通过把所有结果都判为“好”来获得高效用。若沿用当前标准，并预测修改会怎样改变未来行为，修改的激励就不同。论文在信念和初始效用不直接依赖修改、初始策略最优等条件下证明：按当前标准预测修改后行为的规则，可以保持实际行动对原目标的最优性。

决策论把“是否值得修改”也纳入选择

修改和计算都要付出成本。Hay 等研究是否值得再做一次模拟：只有它对最终决策的预期帮助超过成本，才值得继续。Gödel machine 把判断扩展到程序自修改，包括修改证明搜索器；系统先证明现在修改优于继续搜索，再执行修改。这个保证依赖公理和可证明性。现代 RSI 多用任务实验筛选修改，因此下文还需区分证明保证与实验依据。

二、认识与交互：获得证据，还要能够利用证据

选择信息，要看它能否改善行动

目标确定后，学习者还要决定去看什么、试什么。Blackwell 比较两种信息来源：如果只根据信号本身、按固定规则删减或加噪，就能生成另一种信号，那么在目标相同、不计获取成本且能最优使用信息时，保留详细信号不会降低决策价值。这里衡量信息的依据，是它能帮助作出什么选择。

双重控制进一步让行动承担两种作用：完成当前任务，同时试探未知规律。控制实验改变探索成本和未知参数对任务的重要性，检验何时值得为未来学习牺牲眼前收益。信息导向采样（IDS）则把探索指向“哪个行动最好”。它权衡当前选错行动的预期损失与关于最优行动的信息增益；无需同等重视世界中所有未知细节。

相同的信息，对不同学习者未必同样有用

上述决策分析还需要补上一个问题：学习者能否读懂拿到的信息？Xu 等把可用的预测模型限制在集合 $\mathcal{V}$ 中，用这组模型能达到的最低预测损失定义条件 V-熵：

$$H_{\mathcal{V}}(Y \mid X) = \inf_{f \in \mathcal{V}} E[-\log f(X)(Y)]$$

X 是输入，Y 是要预测的结果，f(X)(Y) 是模型分给该结果的概率。比较“不看 X”和“看 X”时的最低损失，就得到输入对这类模型的可用信息。只要允许模型忽略输入，这个差值就非负。仅对输入做确定性处理，不会增加它与预测目标的 Shannon 互信息，却可能让有限模型更容易识别其中的规律。

Abbe 等研究学会简单特征怎样帮助学习复杂特征。例如，目标中包含 x_1、x_1x_2、$x_1x_2x_3$，就提供了逐级扩展的起点。其“合并阶梯”条件把这种结构一般化：乘积项可以排序，每项最多引入一个新变量。若只有孤立的高阶乘积项，就缺少这种低阶学习信号。相关结果针对均匀比特输入、稀疏目标与宽两层网络，使用平均场极限及随输入维数同阶增长的样本规模。它研究的是给定算法能怎样学到结构。

已经学到多少，也可以影响下一步去学什么

Schmidhuber 用压缩进展选择经验：在同一段历史上，新压缩器比旧压缩器省下多少编码长度，就奖励多少。奖励来自实际学到的规律，而非数据仅仅看起来新奇；更新算法可以保持固定。由此，过去的学习结果开始影响未来的经验选择。

Finzi 等的 epiplexity 关注另一个对象：有限计算时间内，数据中有多少结构可被学到。它把描述数据的编码分为两部分：一部分描述模型学到的规律，另一部分记录仍无法预测的内容。在计算时间受限时，选择总编码最短的模型；epiplexity 衡量其中描述规律的编码长度。棋局预训练实验显示，这种结构对不同下游任务的帮助并不相同。因此，“数据有可学结构”“学习已经取得进展”和“任务表现改善”需要分别判断。

认识的自修改：工具、技能与世界模型

现代系统通过不同方式改变与世界的交互。Toolformer 学会使用既有工具，Voyager 把学到的技能保存成新工具，Memento 3 则修改用来预测行动后果的世界模型。三者分别回答怎样调用、怎样复用、怎样理解。

工具与技能：让已有能力成为下一步的资源

Toolformer 让语言模型尝试调用计算器等工具。系统只保留能降低后续文本预测误差的调用样本，再用这些样本训练模型。作者比较同语料下不学工具调用的模型，也检查推理时关掉工具会怎样。计算器带来的额外收益说明，模型学到的调用方式确实有用。被改变的是何时、怎样调用，工具集合和样本筛选规则仍由人给定。

Voyager 在游戏中生成执行动作的代码，根据环境反馈反复修正，再把成功代码存入技能库。后续任务可以直接调用或组合旧技能。移除技能库后，探索更早停滞；新世界任务进一步检验了技能复用。它展示了知识积累如何帮助后续学习。这里增长的是技能内容，选题、检索和自验证规则仍预先设定。

世界模型：用过去的经验预测尚未做过的事

Memento 3 把经验写成描述环境规律的“规则书”，再转成可运行的世界模型。系统先在模型中预测行动后果，再去环境执行，并根据新反馈修订规则。在删除规则书的对照中，两种系统都能完成所选游戏，但保留规则书需要的环境动作更少。这个比较说明，组织和修订经验能够改善下一轮交互。

世界模型还必须接受纠错。Gelman–Shalizi 区分两种工作：在已有模型中更新信念，以及发现模型无法解释数据后修改模型本身。这个区分也说明了 Memento 的验证边界：重现已有经历可以发现部分错误，但多个模型仍可能解释同一历史，对未试过的行动却给出不同预测。要区分它们，还需要新的交互。

三、学习机制：从学习知识到学习更新规则

工具和世界模型改变了系统能做什么；元学习进一步改变系统怎样学。学习型优化器根据梯度历史生成参数更新，架构搜索学习提出哪些网络结构，元强化学习则把交互历史存入循环网络状态，据此适应新任务。最后一种方法在测试时保持网络权重不变，适应发生在内部状态中。

这些工作分别用传统优化器、随机搜索或既有学习规则作比较，检验学得的机制是否有效。但训练这些机制的外层算法仍由人设定。由此引出下一步：负责产生改进的程序，能否也成为系统自己的修改对象？

学习机制的自修改：改进程序也能被改进

STOP 与 DGM：让修改后的程序参与下一轮

找到更好的任务程序，与更会修改程序，需要分开评价。STOP 让一个代码改进程序修改自身，再让新版本去改进一组下游程序，以后者的平均任务表现评价新版本。与初始改进程序、单次推理和贪心迭代相比，部分模型取得收益，较弱模型也可能退化。它把“产生改进的能力”变成了直接优化的对象。

Darwin Gödel Machine（DGM）让修改后的程序既解决编程任务，也负责生成下一轮修改，并保存多个历史版本。作者设置两种对照：始终由最初程序负责修改；只沿最新可用版本继续修改。始终由最初程序负责修改时，后续改善较早趋缓；只保留最新版本时，则更容易被较差修改阻断。比较支持两点：新能力参与后续修改有帮助，历史分支也能保留继续探索的机会。

HyperAgents：进一步修改产生改进方案的过程

DGM 仍由固定的外层流程生成修改指令。HyperAgents 把任务程序和负责修改它的程序一起开放给系统编辑，允许错误诊断、方案生成和后续修改的组织方式发生变化。DGM 依靠编程能力同时支持解题和自修改；HyperAgents 进一步检验这类改进能否迁移到其他任务。两者的推进关系在于可修改范围和迁移证据。

为评价改进能力，作者在测试时固定改进程序，让它从给定任务程序出发生成候选，再用验证集选优、测试集评价。迁移来的改进程序在新任务上带来更大改善。但迁移也带入了任务代码；数学评分的初始失败还包含输出格式错误。因此，这些实验支持整个系统的跨任务迁移，尚未完全分离改进程序自身的贡献。

自修改的效果，需要实验检验

Gödel machine 要求先证明修改有益；DGM 等系统先尝试修改，再用任务实验判断。历史版本即使暂时较弱，也可能被保留，供以后继续修改。基础模型、外部评价和部分版本选择规则仍固定。这使递归改进可以在有限任务上检验，其有效范围也由这些实验条件决定。

持续学习补上一个条件：系统仍需学得动

Dohare 等考察持续训练后的网络还能否学好新任务，这种能力称为“可塑性”。实验发现，常规网络可能逐渐失去可塑性；重置低效用单元可以缓解问题。这与忘掉旧知识是不同的现象。该方法的重置规则由人设定，但它揭示了 RSI 所需的条件：即使新反馈不断到来，系统仍要保有吸收它的能力。

四、反馈怎样支持或限制自我改进

Berk–Nash 解释行动与证据怎样相互支持

反馈能否纠正当前判断，是这些研究的共同问题。Berk–Nash 允许主观模型类错设：行动决定哪些世界回复出现，信念只支持最符合这些回复的模型，实际行动又在该信念下最优。最佳拟合集合由行动频率加权的预测误差决定：

$$\Theta^*(\rho) = \operatorname{argmin}_\theta \; E_{a\sim\rho} \; KL(Q_W(\cdot|a) \;\|\; Q_\theta(\cdot|a))$$

ρ 是行动频率，θ 是主观模型参数；两个 Q 分别表示真实与主观反馈分布，KL 衡量预测差异。信念只给 Θ* 中的模型分配概率，按这些概率计算预期收益；实际采用的行动须使该收益最大。拟合与行动两个条件共同维持这个状态。

自我确认均衡突出未尝试行动上的错误；Berk–Nash 还允许模型无法正确解释已见反馈。扩大探索与修正模型类因此解决不同问题。均衡也不保证收敛：Fudenberg–Lanzani–Strack 证明，在其固定模型类的贝叶斯设定下，若行动收敛，该行动须在所有只支持最佳拟合模型的信念下最优。

GAN 与模型崩溃考察反馈的分辨能力与来源

GAN 的有限判别器理论追问：真实样本已经拿到，评价器能否读出其中的差异？Arora 等表明，缺少大量多样性的生成分布仍可能骗过受限判别器。奖励过优化则显示，持续优化代理评分会扩大它与参考评分的分歧。反馈依据存在，还需要足够的分辨能力。

模型崩溃追问：下一轮数据由谁产生？上一代模型若成为新数据源，采样遗漏与拟合误差会进入后代。数据累积研究通过保留原始与历代数据改变这条传递路径。这与 Berk–Nash 的真实但选择性反馈、GAN 的真实样本参照形成比较：反馈来源、证据覆盖与分辨能力共同影响纠错，各项结论仍依赖各自设定。

棋类与代码为何能利用自生成经验

棋类和代码的反馈分析给出两个具体例子。AlphaZero 自己选择对局，但胜负由规则结算；网络引导搜索，搜索与对局结果又训练网络。CodeRL 自己生成程序，但编译和测试给出执行结果，评价网络再把结果转成训练信号。自己产生候选，不等于自己决定候选正确。

棋类把已知规则的后果经搜索转成训练目标；代码把候选程序经执行转成具体结果。它们都让明确、可重复的检查进入学习，使自生成经验可以反复用于改进下一次选择。

部署还会改变反馈分布

Performative prediction 研究模型部署后引起的数据变化。在强凸、联合平滑且分布变化足够弱等条件下，反复重训可以稳定，却未必达到部署后的最低风险。Miller 等据此研究先学习数据如何响应部署，再利用该响应优化的方法。反馈不仅检验当前模型，也可能随模型行动而改变。

文献解读索引

主题解读：反馈怎样纠正学习者（含棋类与代码）

点击文献名称阅读独立解读。

内部奖励为什么可以不同于最终目标

Eureka 如何用反馈改写训练奖励

改写目标时用哪个目标判断改进

元决策论怎样判断是否值得继续计算

Gödel machine 怎样接受一次自修改

Blackwell 信息怎样改善决策

双重控制 行动也在为后续学习获取证据

信息导向采样 探索应服务于找到最优行动

可用信息 同一份证据为何对不同学习者作用不同

合并阶梯 简单特征怎样成为后续学习的起点

压缩进展 用刚学会的规律选择下一段经验

Epiplexity 有限计算者能够学到多少结构

Toolformer 如何学会调用已有工具

Voyager 如何把技能积累变成后续学习的资源

Memento 3 如何用世界模型改进下一轮交互

模型批判为什么不能由后验更新代替

学习型优化器如何学会更新另一个模型

架构搜索怎样学习提出更好的模型

权重不变时系统怎样继续学习

STOP 怎样评价产生改进的程序

DGM 如何让后代程序继续参与自修改

HyperAgents 怎样把改进过程也纳入修改

持续学习为什么还需要保持可塑性

自我确认均衡 为什么正确的反馈仍能留下错误判断

Berk–Nash 均衡如何解释反馈中的错误自洽

内生错设学习 哪些自洽状态能成为长期结果

Performative prediction 预测模型怎样改变下一轮数据

Outside the Echo Chamber 怎样优化部署反馈后的表现

模型崩溃 为什么只学习上一代输出会逐渐丢失内容

数据累积 为什么保留历史会改变自训练的长期误差

奖励过优化 为什么代理分数提高而参考表现下降

有限判别器 分不清两个分布不等于它们相同